

Núm. 1217  
2022



tá - Colombia - Bogotá - Colombia - Bogotá - Colombia - Bogotá - Colombia - Bogotá - Colombia - Bogotá - Colombia - Bogotá - Col

# Detección de Anomalías y Poder de Mercado en el Sector Eléctrico Colombiano<sup>\*</sup>

Alvaro J. Riascos Villegas<sup>\*\*</sup>

Julian Chitiva<sup>\*\*\*</sup>

Carlos Salazar<sup>\*\*\*\*</sup>

La serie Borradores de Economía es una publicación de la Subgerencia de Estudios Económicos del Banco de la República. Los trabajos son de carácter provisional, las opiniones y posibles errores son responsabilidad exclusiva de los autores y sus contenidos no comprometen al Banco de la República ni a su Junta Directiva

## Resumen

En este trabajo introducimos una metodología de generación de alertas de potenciales prácticas anticompetitivas en el mercado mayorista de electricidad colombiano. La metodología se compone de dos partes: (1) Con base en la disponibilidad declarada de los agentes, se identifican aquellos que potencialmente pueden tener un impacto alto en el precio de bolsa (i.e., pivotaes en el sentido del índice de oferta residual - *IOR*) y (2) Usando métodos de aprendizaje de máquinas se identifican las ofertas de energía (i.e., precios) de aquellos agentes pivotaes que, de acuerdo al estado del mercado y su historia (i.e., oferta pasadas, recursos hídricos, tecnología de generación, etc.) se podrían considerar atípicos o anómalos. Con base en estos dos indicadores se generan alertas de potenciales prácticas anticompetitivas. Reportamos los resultados de la aplicación de esta metodología al mercado mayorista colombiano en el período Agosto 16, 2018 - Julio 30, 2019. Una característica importante de esta metodología es que puede ser aplicada con la información disponible del operador del sistema, 24 horas antes de que se observen los resultados del mercado y generando alertas *ex-ante* a la realización de los eventos. Esta posibilidad de generar alertas casi en tiempo real es aun más importante de cara al nuevo mercado intradiario que próximamente entrará en rigor en el sistema eléctrico colombiano.

**Clasificación JEL:** C22, C45, C53, P18, Q41, Q47.

**Palabras Clave:** Mercados Eléctricos, Detección de Anomalías, Poder de Mercado, Machine Learning.

---

<sup>\*</sup>Todos los datos de este artículo son públicos y disponibles desde el portal de XM SA ESP, administrador y operador del sistema eléctrico colombiano. Agradecemos a David Cardona (XM) por su colaboración en el entendimiento de los datos, a Juan Esteban Carranza y Juan David Martín por sus comentarios a las primeras versiones del trabajo, a los participantes del II Foro XM en Cartagena de Indias, Septiembre de 2019, al equipo de investigadores del CEPCO - Banco de la República, Cali y a los participantes del Seminario de Matemáticas Aplicadas de Quantil. Uno de los autores, Alvaro Riascos, agradece la financiación recibida por el Banco de la República para la realización de este trabajo.

<sup>\*\*</sup>Universidad de los Andes, Quantil, CEPCO - Banco de la República. alvaro.riascos@quantil.com.co

<sup>\*\*\*</sup>HEC Paris, Centro de Analítica para Políticas Públicas - CAPP. julian.chitiva@quantil.com.co

<sup>\*\*\*\*</sup>Universidad de los Andes. ca.salazar@uniandes.edu.co

# Anomaly Detection and Market Power in Colombian Electricity Market<sup>\*</sup>

Alvaro J. Riascos Villegas<sup>\*\*</sup>

Julian Chitiva<sup>\*\*\*</sup>

Carlos Salazar<sup>\*\*\*\*</sup>

The views expressed in this paper are those of the authors and do not necessarily reflect the views of the Banco de la República or its Board of Governors.

## Abstract

We introduce a methodology for generating alerts of potential anti-competitive practices in the Colombian wholesale electricity market. The methodology is made up of two parts: (1) Based on the declared availability of the agents, those that can potentially have a high impact on the stock price are identified (*i.e.*, pivotal in the sense of the residual supply index - *IOR* ) and (2) Using machine learning methods, the energy offers (*i.e.*, prices) of those pivotal agents are identified that, according to the state of the market and its history (*i.e.*, past offers, water resources, generation technology, etc.) could be considered atypical or anomalous. Based on these two indicators, alerts of potential anti-competitive practices are generated. We report the results of the application of this methodology to the Colombian wholesale market in the period August 16, 2018 - July 30, 2019. An important characteristic of this methodology is that it can be applied with the information available from the system operator, 24 hours before that the results of the market are observed and generating alerts *ex ante* to the realization of the events. This possibility of generating alerts almost in real time is even more important in view of the new intra-day market that will soon come into force in the Colombian electricity system.

**JEL Classification:** C22, C45, C53, P18, Q41, Q47.

**Keywords:** Pool Electricity Markets, Anomaly Detection, Market Power, Machine Learning.

---

<sup>\*</sup> All the data in this article is public and available from the system operator website, XM SA ESP. We thank David Cardona (XM) for his collaboration in understanding the data, Juan Esteban Carranza and Juan David Martin for their comments on the first versions of this paper, and the participants of the II XM Forum in Cartagena de Indias, September 2019, to the team of researchers from CEPCO - Banco de la República, Cali and to the participants of the Quantil's Applied Mathematics Seminar. One of the authors, Alvaro Riascos, would like to acknowledge financial support from the Banco de la República.

<sup>\*\*</sup> Universidad de los Andes, Quantil, CEPCO - Banco de la República. alvaro.riascos@quantil.com.co

<sup>\*\*\*</sup> HEC Paris, Centro de Análítica para Políticas Públicas - CAPP. julian.chitiva@quantil.com.co

<sup>\*\*\*\*</sup> Universidad de los Andes. ca.salazar@uniandes.edu.co

# 1. Introducción

La liberalización del sector eléctrico Colombiano ha tenido como uno de sus principales propósitos promover la eficiencia de la prestación de un servicio esencial para la sociedad de forma confiable y con calidad. Desde un punto de vista económico, en mercados descentralizados la prescripción normativa para ser eficientes es promover la competencia (i.e., mitigar el poder de mercado). El problema es cómo garantizar una operación eficiente en un mercado con la características propias del mercado eléctrico: Demanda inelástica, concentración de mercado, altos costos de almacenamiento, etc.

Una forma de racionalizar las dificultades que estas características del mercado imponen al propósito de producir de forma eficiente es utilizando el modelo de Cournot. En un mercado con pocas firmas que producen un bien homogéneo y sin restricciones de capacidad, en competencia a la Cournot, el equilibrio de Nash - Cournot satisface la Ecuación 1, donde  $CM_i$  es el costo marginal del recurso de generación  $i$ ,  $P$  es el precio de venta (i.e., precio de bolsa),  $\epsilon$  es la elasticidad de la demanda agregada del mercado,  $Q_i$  es la disponibilidad declarada del recurso  $i$  y  $Q$  la demanda agregada. Como puede observarse de esta Ecuación entre menor es la elasticidad de la demanda o mayor es la participación de una firma en el mercado, mayor es el *markup* (el precio de venta de la energía por encima de sus costos marginales). Las implicaciones de no poder almacenar la energía de forma eficiente también pueden intuirse de esta Ecuación. En equilibrio  $Q$  es igual a la oferta agregada y, por lo tanto, ante una restricción de la oferta (voluntaria o no) o bien la demanda tiene que ajustarse, aumentando el poder de mercado de algunos recursos, o la energía almacenada se utiliza para suplir la deficiencia en la oferta. Dado que este segundo escenario es muy costoso, la consecuencia de no poder almacenar la energía implica que algunos agentes tienen mayor poder de mercado.<sup>1</sup>

$$Markup \equiv \frac{P - CM_i}{P} = -\frac{1}{\epsilon} \frac{Q_i}{Q} \quad (1)$$

Sobre este problema la experiencia y el consenso internacional sugieren que (véase Twomey, Green, Neuhoﬀ, y Newbery (2005)), a la par de la creación de mercados competitivos para la generación de electricidad, es necesario introducir un mecanismo de monitoreo y seguimiento del mercado tal que: (1) Permita identificar potenciales abusos de poder de mercado y (2) Introduzca medidas de mitigación *ex-ante* y/o punitivas *ex-post*. Este es el caso de, por ejemplo, OFGEM (Gran Bretaña), Nordpool (países Escandinavos), FERC (Estados Unidos), NYISO (Nueva York), PJM (Centro Estados Unidos), CAISO (California), etc. Véase Bataille, Steinmetz, y Thorwarth (2014).

En el ámbito nacional la Superintendencia de Industria y Comercio (SIC) elaboró una herramienta que permite analizar: (1) Contratos bilaterales; (2) La bolsa de energía y (3) Las reconciliaciones positivas.<sup>2</sup> Para esto sugieren la utilización de indicadores del margen sobre precio de escasez; tolerancia a condición crítica y un indicador de condición operativa del recurso. Sin embargo, esta herramienta no explota las ofertas de mercado, estrategia mediante la cual los actores pueden potencialmente manipular el mercado spot (o mercado de un día antes para ser más precisos). Recientemente, la Superintendencia de Servicios Públicos Domiciliarios (SSPD) acaba de introducir el UMMEG (Unidad de Monitoreo de Mercados de Energía y Gas). Sin

---

<sup>1</sup>En sistemas con un componente importante de energía hídrica, los embalse pueden considerarse una forma de almacenamiento. Sin embargo, en situaciones críticas de escasez de agua su capacidad de mitigar este riesgo de ejercer poder de mercado es menor.

<sup>2</sup>Véase SSPD (2017): Sistema de Monitoreo y Evaluación de Obligaciones de Energía Firme (SIMEO).

embargo, no existen detalles públicos sobre la metodología utilizada.

Por otra parte, la literatura académica internacional, por ejemplo Twomey y cols. (2005), Wolak (2004), Newberry (2008) y Swinand, Scully, Foulkes, y Kessler (2007), todos coinciden en la necesidad de introducir metodologías cuantitativas de monitoreo del mercado spot. En el caso colombiano la literatura es escasa y los únicos estudios que se encuentran son: Botero, García, Vélez, y Guillermo (2013). Comisión de Regulación de Energía y Gas (CREG) (2010). Ambos documentos discuten el concepto de Índice de Oferta Residual (*IOR*) que introduciremos más adelante y que es central en este trabajo, pero ninguno de los dos documentos sugiere cómo acoplar este indicador a un sistema de detección de anomalías en la ofertas de los agentes tal y como se hace en este trabajo. En la metodología que aquí se propone, el *IOR* juega un papel relevante para determinar el impacto potencial de un intento de manipulación de mercado, pero no para identificar las posibles anomalías en el comportamiento. Aquí las anomalías se identifican estudiando la distribución de la ofertas utilizando técnicas de aprendizaje de maquinas (véase Goodfellow, Bengio, y Courville (2016)).

## 2. Metodología

Este trabajo propone una estrategia de monitoreo basada en tres pilares: (1) Identificar aquellos agentes que potencialmente pueden tener un impacto importante en el mercado (i.e., pivotaes). Para esto usamos el *IOR*. (2) Entre aquellos pivotaes, identificar comportamientos atípicos a través de sus ofertas en el mercado mayorista (spot). Para identificar este comportamiento primero identificamos el comportamiento normal y generamos alertas cuando las ofertas observadas tienen una probabilidad baja de ser observadas bajo la hipótesis de comportamiento normal y (3) Validar el impacto *ex-post* de una potencial conducta anticompetitiva. Este trabajo no discute ninguna metodología especial para esta validación pero la estrategia estándar en la industria es simular el costo económico del despacho cuando el agente bajo consideración utiliza una oferta que refleje sus costos marginales (regulatorios) en comparación con el costo económico del despacho cuando participa con la oferta observada. Esta diferencia es la base para una penalización *ex-post*.

Vale la pena mencionar que los pasos (1) y (2) de esta metodología pueden ser implementados de forma *ex-ante* a la ejecución del mercado, permitiendo generar alertas de comportamiento anti-competitivo. Los agentes participantes podrían afrontar el riesgo de ser o no investigados una vez realizado el despacho y estimado el impacto (externalidad).

En cualquier caso, la innovación metodológica de este trabajo consiste en introducir una metodología de detección de anomalías de las ofertas de los agentes basadas en técnicas de aprendizaje de máquinas. La detección de anomalías se hace primero prediciendo, mediante diferentes metodologías, el valor a ofertar de un determinado recurso teniendo en cuenta variables como la capacidad, si está en periodo de sequía (fenómeno de El Niño), la **Demanda Comercial**, entre otras. Posteriormente, se calcula la diferencia con la oferta real, si esta diferencia supera un umbral determinado esta oferta puede ser una anomalía. Finalmente, para determinar con cuál modelo se harán las predicciones para un determinado recurso se selecciona el que menor error tenga con respecto a dicho recurso sobre datos de entrenamiento previamente filtrados o que tienen un comportamiento normal.

### 3. Datos

La información utilizada es pública y disponible del portal del operador y administrador del sistema eléctrico colombiano XM S.A. E.S.P y contiene observaciones diarias entre 2003 y 2019 para 70 recursos de generación en el mercado eléctrico colombiano.

Los datos constituyen un panel que incluye observaciones de las variables disponibilidad, tecnología, capacidad, *heat rate*, **Demanda Comercial**, fenómeno del niño, demanda y oferta. Posteriormente, se eliminan aquellos recursos que contaran con más de 1 % datos faltantes y cuya tecnología fuera diferente a hídrica y, térmica con carbón o gas. Finalmente, debido a un cambio en la metodología de la subasta utilizada por el gestor del mercado para determinar el despacho se consideran solo datos posteriores a 1 de enero de 2010. Con lo anterior, para el presente documento se utilizan datos diarios de 36 recursos entre el 1 de enero de 2010 y el 31 de julio de 2019 para un total de 125.856 observaciones. El Cuadro 1 describen las variables que se utilizan en el presente estudio.

| Variable          | Tipo       | Descripción  |
|-------------------|------------|--|
| Disponibilidad    | Continua   | MWh disponibles que oferta un recurso para una hora del día.   |
| Tecnología        | Categórica | Tecnología de generación usada por el recurso  |
| Capacidad         | Continua   | Capacidad instalada efectiva (MW)  |
| <i>Heat rate</i>  | Continua   | Cociente entre la energía térmica aportada y la energía eléctrica generada.  |
| Fenómeno del niño | Binaria    | Indica si en la fecha en la que se tomaron los datos estaba presente el Fenómeno del Niño (1 de septiembre de 2015 - 31 de mayo de 2016)   |
| Demanda comercial | Continua   | Valor de la demanda real del comercializador, afectada con las pérdidas en las Redes de Transmisión Regional o de Distribución Local y las pérdidas del Sistema de Transmisión Nacional. |
| Demanda Oferta    | Continua   | Diferencia entre la <b>Demanda Comercial</b> promedio y la disponibilidad fija promedio.   |
| Oferta            | Continua   | Precio al cual un recurso está dispuesto a vender energía durante el día.  |

Cuadro 1: Tipos de variables. Fuente: XM.

#### 3.1. Estadísticas descriptivas

La Figura 1 muestra los histogramas de las variables utilizadas en el análisis del presente documento. Adicionalmente, la variable Oferta cuenta con una alta proporción de valores por debajo de 1,000 lo cual es consistente con la proporción de datos en periodos de Fenómeno del Niño que es cuando se observan precios altos. Por otra parte, las variables **Demanda Comercial** y **Demanda Oferta** parecen seguir una distribución Normal. Finalmente, en la Figura 1e se observa que gran parte de los recursos tienen una capacidad instalada inferior a 200 MW, lo cual podría interpretarse como recursos con bajo poder de mercado. Es de resaltar que se cuenta con más información de los recursos cuya tecnología de generación es agua, como se muestra en el Cuadro 2.

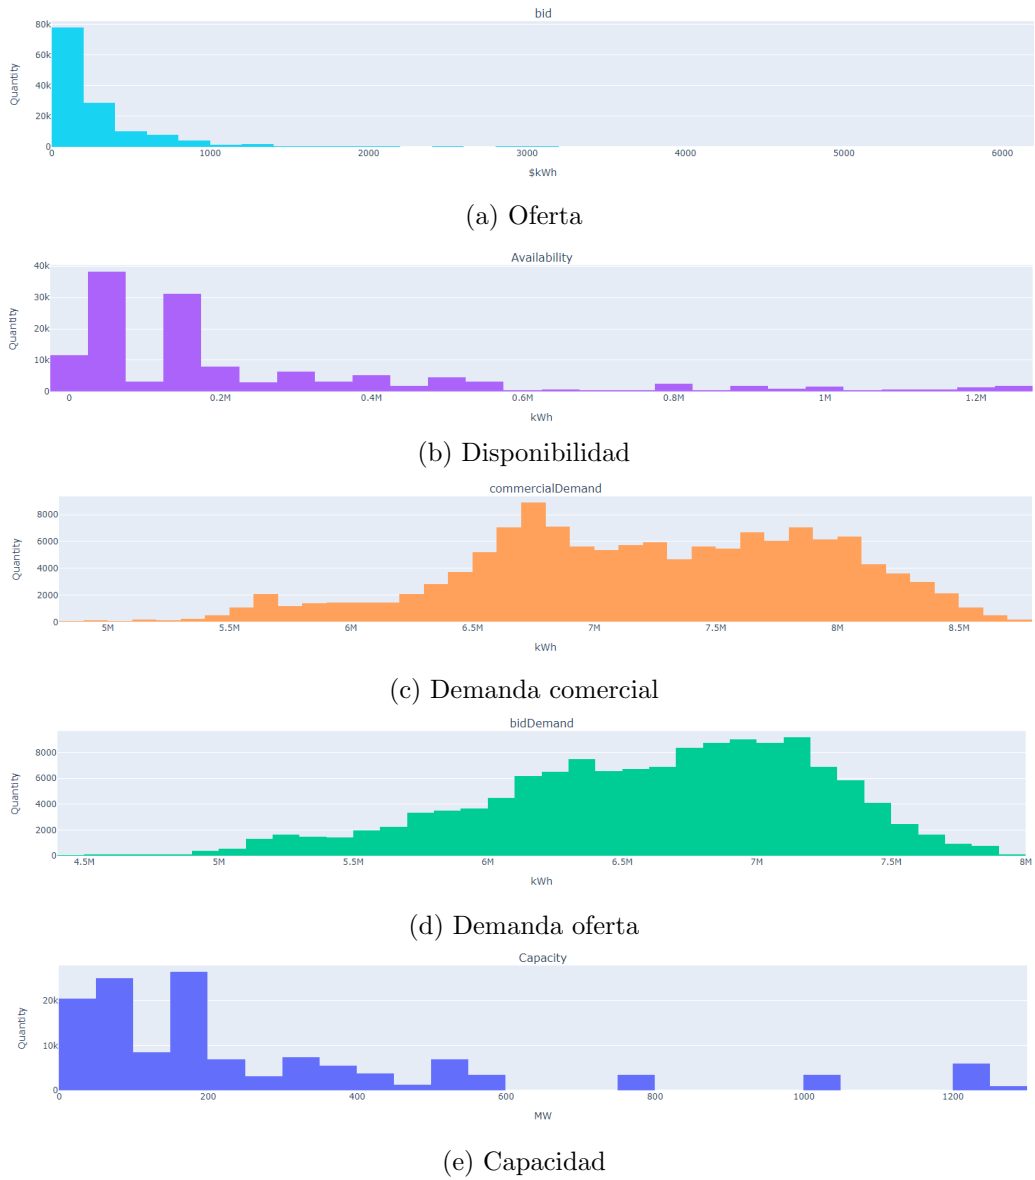


Figura 1: Distribución de las variables utilizadas. Fuente: XM. Cálculos del Autor.

| Tecnología | # Recursos |
|------------|------------|
| Agua       | 15         |
| Gas        | 10         |
| Carbón     | 11         |

Cuadro 2: Recursos por tecnología. Fuente: XM. Cálculos del autor.

En las Figuras 2a y 2b se reporta el comportamiento a lo largo del tiempo de las principales variables utilizadas. Las Figuras también muestran el periodo de Fenómeno del Niño. Adicionalmente, en las Figuras 2c y 2d se puede observar un comportamiento creciente de las variables Demanda Comercial y Demanda Oferta (Cuadro 1).



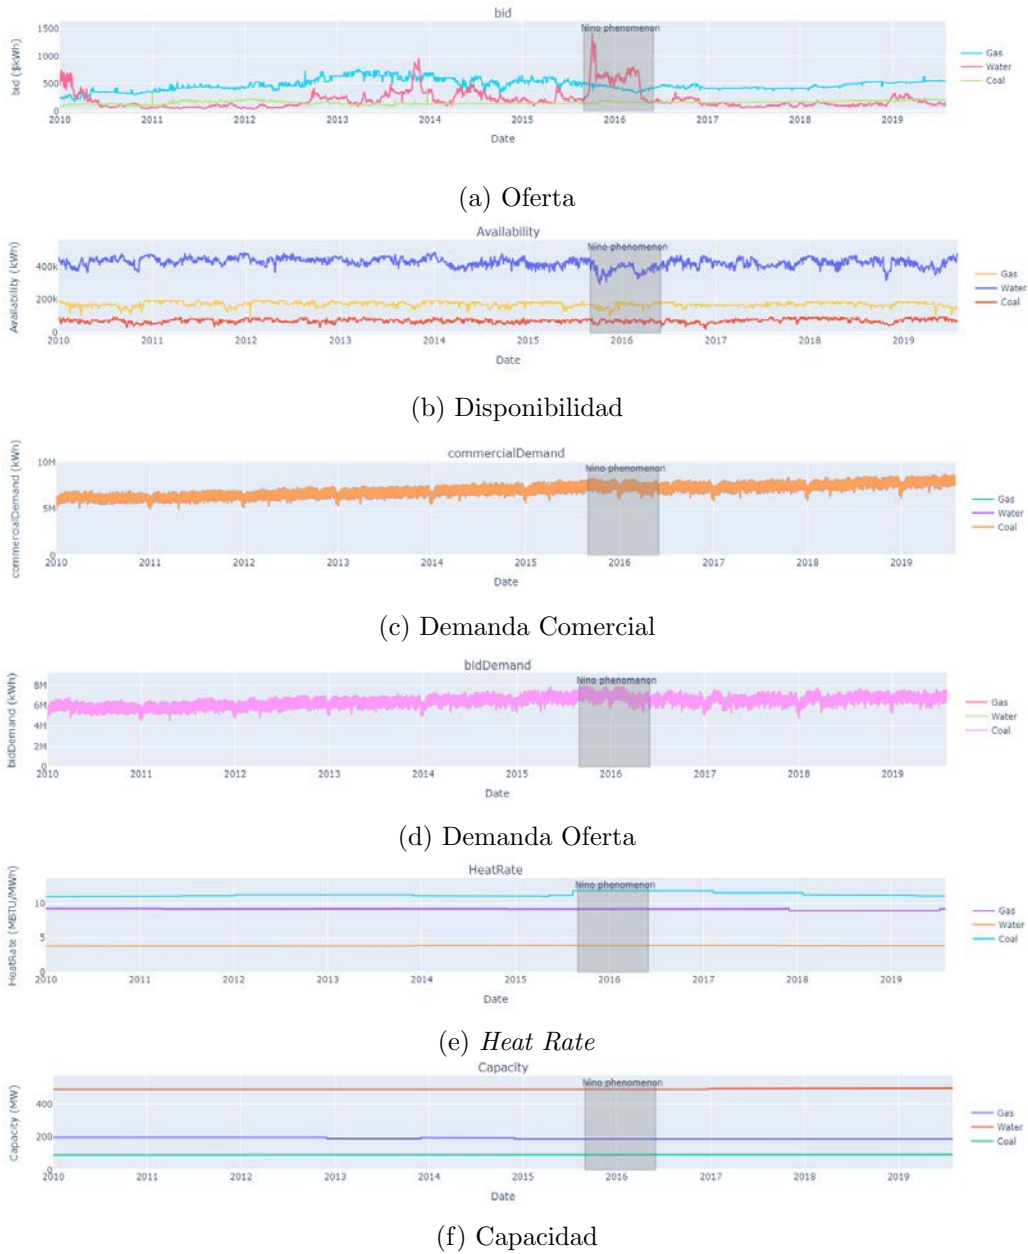


Figura 2: Comportamiento de las variables en el tiempo agrupado por tecnología. Fuente: XM. Cálculos del autor. En las Figuras 2a y 2b se observa un comportamiento levemente estable de las ofertas y disponibilidades, exceptuando aquellos periodos en los que está presente el Fenómeno del Niño para los recursos que usan como tecnología de generación agua. Adicionalmente, en las Figuras 2c y 2d se puede observar un comportamiento al alza de las variables Demanda Comercial y Demanda Oferta (Cuadro 1).



## 4. Impacto

### 4.1. índice de oferta residual

Para medir el potencial impacto que tendría en el mercado el comportamiento atípico de los jugadores<sup>3</sup>, vamos a utilizar el Índice de Oferta Residual (*IOR* o *RSI*, por sus siglas en inglés) por firma por hora. Este índice es una generalización del concepto de agente pivotal y es la base para identificar cuándo la oferta de un agente pone en riesgo la satisfacción de la demanda. La Ecuación 2 define el *IOR* del jugador  $i$ , donde  $N$  es el conjunto de jugadores,  $Q_k$  es la oferta (declarada) por el jugador  $k$  y  $Q$  es la demanda total. Intuitivamente el  $IOR_i$  mide qué tan relevante es la oferta del jugador  $i$  en la oferta total. Cuando el  $IOR_i$  de un jugador es menor que uno, esto quiere decir que la oferta del jugador  $i$  es critica para satisfacer la demanda del sistema. Por el contrario, si el  $IOR_i$  es mayor que uno este es una indicación de que el jugador tiene menos poder de mercado y, por lo tanto, puede tener menor influencia sobre el precio spot.

$$IOR_i = \frac{\sum_{j \in N} Q_j - Q_i}{Q} \quad (2)$$

Volviendo al modelo de Cournot, en equilibrio no es difícil ver que el  $IOR_i$  esta relacionado con el *Markup* de acuerdo a la Ecuación 3, donde  $ND$  son los recursos no despachados.

$$Markup \equiv \frac{P - CM_i}{P} = -\frac{1}{\epsilon} \left( 1 + \frac{1}{Q} \sum_{j \in ND} Q_j - IOR_i \right) \quad (3)$$

La Figura 3 muestra el resultado de calcular el *IOR* por recurso en el caso del sector eléctrico colombiano. En esta gráfica se incluyen importaciones y excluimos recursos determinísticos (no restamos los contratos al no existir información pública horaria lo cual subestima el *IOR*). De otra parte, tampoco tenemos información de mantenimientos dado que no es información pública, ni fallas en la operación (lo cual implica que sobrestimamos la oferta residual y por lo tanto el *IOR*). Ahora, en el caso colombiano realmente son pocos los agentes que controlan la mayoría de los recursos de generación. En efecto, aproximadamente 5 agentes controlan más del 85 % de la generación diaria del país. La Figura 4 muestra el *IOR* por agente en la cual se observan indicadores más cercanos a uno, que es el umbral critico. Finalmente, nos concentramos en estudiar el *IOR* (por agente) diferenciando entre horas pico y horas valle (7pm - 9pm y 12am - 5am respectivamente) cuyos resultados se muestran en la Figura 5.

---

<sup>3</sup>Los jugadores pueden ser recursos, que son las unidades efectivas de producción de energía, o agentes, los cuales son conjuntos de recursos que pertenecen a un mismo propietario.




Figura 3: *IOR* o RSI (*Residual Supply Index* por sus siglas en inglés) por recurso. Fuente: XM. Cálculos del autor.




Figura 4: *IOR* o RSI (*Residual Supply Index* por sus siglas en inglés) por agentes. Fuente: XM. Cálculos del autor.

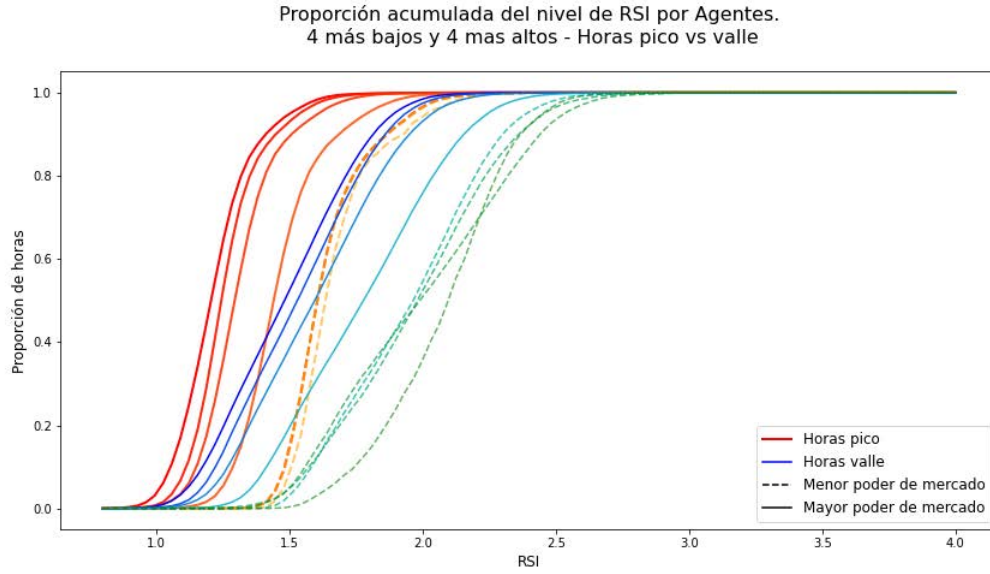


Figura 5: *IOR* o RSI (*Residual Supply Index* por sus siglas en inglés) por agentes horas pico vs. valle. Fuente: XM. Cálculos del autor.

#### 4.2. Validación *markups* y contratos

Si bien la teoría económica sugiere que el *IOR* refleja poder de mercado, en esta sección se muestra evidencia empírica de este hecho.

La Figura 6 muestra la relación entre los *markups* basados en costos marginales, estimados desde un punto de vista de ingeniería como en Riascos, Bernal, de Castro, y Oren (2016). Como puede observarse entre mayor es el *IOR* menor es el *markup*, en concordancia con la teoría.




Figura 6: Relación entre el *markup* y el *IOR*. Fuente: XM. Cálculos del autor.

Otra forma de validar la intuición sobre lo que mide el *IOR* es estudiar la relación con los contratos bilaterales entre comercializadores y agentes. Una vez más, si usamos como marco de

referencia para pensar sobre este problema el modelo de Cournot, obsérvese que entre mayor sea el número de contratos (netos) que un agente tiene firmados, reduciendo su explosión neta a bolsa (menor disponibilidad comercial), menor es el poder de mercado y mayor el *IOR*. Luego, entre mayor sea la posición neta en contratos y menor incentivos a manipular el precio, menor es el *markup* del agente (y mayor el *IOR*). La Figura 7 muestra esta relación entre la disponibilidad neta de contratos y el *IOR*, en concordancia con la teoría económica.




Figura 7: Relación entre el *IOR* y disponibilidad comercial. Fuente: XM. Cálculos del autor.

## 5. Modelos para predicción de ofertas

Para poder detectar comportamientos atípicos en las ofertas de los recursos en el mercado spot es necesario hacer una predicción del precio ofertado por recurso sujeto a las condiciones del mercado en las que se encuentre el agente haciendo su oferta. Dentro de las condiciones del mercado que pueden afectar el precio ofertado por un recurso en un día determinado se encuentran la demanda del mercado, la tecnología que usa el recurso, si está en un periodo afectado por el Fenómeno de El Niño y las ofertas de los demás recursos, entre otros.

Estimamos dos tipos de modelos de oferta conceptualmente distintos. En el primero suponemos que los agentes no observan las ofertas de los demás excepto ofertas históricas y todas las demás variables que se usan en la predicción. En el segundo las estimaciones que se hacen son de modelos no paramétricos de la mejor respuesta en la oferta de los recursos frente a la expectativa que cada uno hace de la oferta de los demás. Esta expectativa que cada agente tiene se supone que, en el Equilibrio de Nash Bayesiano del juego entre los recursos de generación, coincide con las ofertas de los demás. En resumen, bajo el supuesto de estar en un Equilibrio de Nash Bayesiano, estimamos de forma no paramétrica, usando modelos de aprendizaje de máquinas, la mejor respuesta en la oferta diaria de cada recurso frente a las ofertas de los demás.

## 5.1. Preprocesamiento de los Datos

### 5.1.1. Filtrado

Los datos fueron filtrados teniendo en cuenta que la diferencia absoluta entre el precio bolsa promedio hasta el día previo y la oferta del día actual no fuese superior a 2 veces la desviación estándar del precio bolsa hasta el día previo de manera que se evitaran posibles valores anómalos correspondientes casos en que los agentes no quieren vender ofertando a un precio muy alto o quieren vender ofertando a un precio muy bajo.

$$|y_t - \mu_{t-1}| < 2 * \sigma_{t-1} \quad (4)$$

Donde:

$y_t$  = Oferta del día  $t$

$\mu_{t-1}$  = Precio bolsa promedio hasta el día  $t-1$

$\sigma_{t-1}$  = Desviación estándar del precio bolsa hasta el día  $t-1$

### 5.1.2. Datos ventana

En el caso de los datos ventana se construyen ventanas de datos con  $s + 1$  observaciones cada una ordenadas cronológicamente del mismo recurso,  $s$  corresponde al número de días anteriores a tener en cuenta y el 1 que se añade proviene del hecho de que los agentes ofertan según sus valores del día actual para cada variable. El tamaño de la ventana elegido es de 7 días.

Por ejemplo, sea  $t$  el momento en que queremos hacer un pronóstico un día adelante. Sea  $y_t$  el valor de la variable objetivo en el momento  $t$  y  $x_i$  el valor de la variable  $i$ . Una ventana, sin la variable objetivo para todos los períodos, teniendo  $s = 2$  y  $n$  variables se representará como se muestra en el Cuadro 3 y visualmente se ve como en la Figura 8 . Estas ventanas no se superponen entre sí.

| Tiempo  | $x_i$ | $x_{i+1}$ | ... | $x_{n-1}$ | $y$  |
|---------|-------|-----------|-----|-----------|------|
| $t - 2$ | 0     | 0.21      | ... | -0.05     | 1.03 |
| $t - 1$ | 0.6   | 0.12      | ... | -0.003    | 0.60 |
| $t$     | 0.57  | 0.21      | ... | -0.053    | 0    |

Cuadro 3: Estructura ejemplo de datos ventana.




Figura 8: Ejemplo de datos ventana.

Para esta estructura de datos la oferta de los demás recursos es una variable para el recurso  $j$  y, para fines prácticos, en caso de que no se quiera tener en cuenta la oferta de los demás recursos en el tiempo  $t$  la ventana sería de tamaño  $s$  y se crearía una fila para el tiempo  $t$  que no incluya esta información.

### 5.1.3. Conjuntos de Entrenamiento, Prueba y Validación

Tras realizar el filtrado quedaron 93.261 datos que fueron separados en tres conjuntos: entrenamiento, validación y prueba. El primer 70 % cronológicamente ordenado para cada recurso pertenece al conjunto de entrenamiento, El siguiente 20 % pertenece al conjunto de validación y el 10 % restante al conjunto de prueba. Las fechas cubiertas y proporción del total de los datos y tamaño de cada conjunto están presentados en el Cuadro 4




Figura 9: Distribución de las observaciones para un recurso.

| Conjunto      | Proporción | Cantidad | Rango de fechas                  |
|---------------|------------|----------|----------------------------------|
| Entrenamiento | 70.1 %     | 65375    | Enero 3, 2010 - Marzo 11, 2017   |
| Validación    | 18,68 %    | 17421    | Marzo 12, 2017 - Agosto 15, 2018 |
| Prueba        | 11,22 %    | 10465    | Agosto 16, 2018 - Julio 30, 2019 |

Cuadro 4: Descripción de los datos de entrenamiento, validación y prueba.

### 5.1.4. Normalización y Variables *Dummy*

Teniendo en cuenta la distribución de las variables, cada una de las variables continuas se normalizó para mejorar el rendimiento y la estabilidad del modelo durante el entrenamiento. La técnica seleccionada para normalizar estas variables fue el *Z-Score*, que garantiza que las variables tendrán una media de 0 y una desviación estándar de 1 y utiliza la media ( $\mu$ ) y la desviación estándar ( $\sigma$ ) del conjunto de entrenamiento, como se muestra en la Ecuación 5. Posteriormente, las variables categóricas y los códigos de los distintos recursos fueron transformados en variables *dummy*, cada uno de los posibles valores de estas variables se convierte en un variable binaria, 1 indica la presencia del valor y 0 su ausencia.

$$x' = \frac{x - \mu}{\sigma} \quad (5)$$

## 5.2. Modelos

### 5.2.1. Modelo Ingenuo o Base

El punto de partida, considerado como el modelo ingenuo o modelo base, es un modelo que hace una predicción ingenua donde el valor predicho corresponde al valor del día anterior. Este modelo a pesar de ser el más sencillo es bastante importante pues establece un punto de referencia de rendimiento predictivo mínimo de los modelos.

### 5.2.2. Modelo Auto-regresivo Integrado de Media Móvil (ARIMA)

A diferencia del modelo base, el modelo ARIMA puede utilizar no solo 1 valor en el pasado sino más de manera que pueda encontrar patrones que le permitan predecir con mayor precisión. Para esto el modelo ARIMA requiere 3 parámetros que indican el orden de las componentes que integran el modelo (auto-regresiva, integrada y de media móvil). Para cada recurso se ajustó un modelo ARIMA cuyos parámetros se obtuvieron con la ayuda de la librería para python *pmdarima*

### 5.2.3. Redes Neuronales Recurrentes (RNN)

Las redes neuronales recurrentes permiten tratar datos secuenciales de forma eficiente y, dependiendo del tipo de bloques usados, tener presentes dependencias a corto y largo plazo. Para este tipo de redes neuronales recurrentes se usaron datos ventana teniendo en cuenta la información de los demás recursos para el día a predecir (i.e., mejor respuesta) y sin tener en cuenta las ofertas de los demás del mismo día. La Figura 10 muestra la arquitectura básica de una red neuronal recurrente.

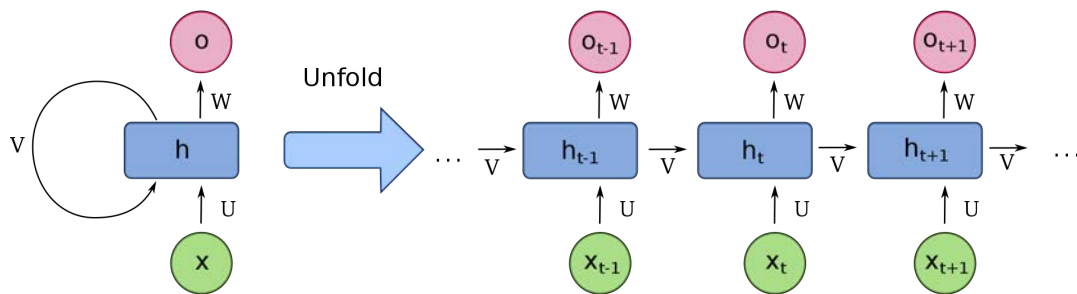


Figura 10: Arquitectura básica de una red neuronal recurrente (poco profunda). En la parte de inferior de la Figura, la capa de entrada, son vectores  $x_t$  con información histórica de las variables de interés. Las funciones  $h_t$  se encuentran en la capa oculta de la red y transforman las entradas en salidas  $O_t$  y pasan información al siguiente periodo. Se utilizan pesos  $W$  y  $V$  respectivamente para ponderar las salidas de cada capa oculta. Fuente: Wikimedia Commons.

Para los modelos de redes neuronales recurrentes el número máximo de épocas de entrenamiento fue de 1000, también se implementó una función de *callback* que monitorea la pérdida del conjunto de validación y guardaba los pesos cada vez que esta disminuía. Los hiper-parámetros como el número de unidades para cada capa, número de capas, función de activación de cada capa y el optimizador se encontraron con búsqueda aleatoria aunque se intentaron también *Hyperband* y optimización bayesiana, cada combinación de hiper-parámetros se aplicó a un modelo y se evaluó utilizando como métrica el MSE, se eligió el mejor rendimiento sobre los datos de validación después de 300 épocas. El espacio de búsqueda para los algoritmos de afinación de los modelos es presentado en el Cuadro 5. Para evitar co-dependencias entre unidades y hacerlas robustas ante diferentes entradas (Goodfellow y cols. (2016)) se usó la técnica de regularización *dropout* con probabilidad de 0.5 lo que significa que una de cada 2 entradas será excluida aleatoriamente en cada paso durante el entrenamiento, esto se hizo antes de la capa de salida.



| Hiperparámetro                            | Posibles valores                        |
|---|---|
| # de capas densas                         | 0, 1, 2, 3, 4, 5                        |
| # unidades por capa                       | $2^n \forall n \in \{1, 2, \dots, 10\}$ |
| # capas T2V                               | 0, 1                                    |
| Tipo de capa recurrente                   | LSTM, GRU                               |
| Funciones de activación (capa T2V)        | cos, sin                                |
| Funciones de activación (capa recurrente) | Tanh, Sigmoid                           |
| Funciones de activación (capas densas)    | Tanh, Sigmoid, ReLu, Lineal, Selu       |
| Tasa de aprendizaje                       | $10^{-n} \forall n \in \{1, 2, 3, 4\}$  |
| Optimizador                               | ADAM, SGD                               |

El número de unidades por capa varía por cada capa. El número de capas recurrentes fue fijado en 1.

Cuadro 5: Espacio de búsqueda.

#### 5.2.4. Transformación Time to Vector (T2V)

La transformación T2V propuesta en Kazemi y cols. (2019) permite capturar características del tiempo principalmente con ayuda de funciones de activación periódicas y representarlas en un vector que puede ser usado por varios modelos para mejorar su desempeño. La transformación  $\mathbf{t2v}$  está definida en 6

$$\mathbf{t2v}(\tau)[i] = \begin{cases} \omega_i \tau + \varphi_i, & \text{Si } i = 0. \\ f(\omega_i \tau + \varphi_i), & \text{Si } 1 \leq i \leq k. \end{cases} \quad (6)$$

Donde  $\tau$  es una noción escalar del tiempo,  $\mathbf{t2v}(\tau)$  la representación en vector de  $\tau$ ,  $\mathbf{t2v}(\tau)[i]$  es el  $i$ -ésimo elemento de la representación,  $f$  es una función periódica y tanto  $\omega_i$  como  $\varphi_i$  son los parámetros ajustables o estimables que corresponden a la frecuencia y desfase de la función periódica respectivamente. El término lineal de esta transformación ayuda a capturar patrones no periódicos.

#### 5.2.5. Gated Recurrent Unit (GRU)

Es un bloque de red recurrente complejo que puede manejar dependencias a largo plazo con 2 puertas que pueden aprender qué datos son importantes o no al olvidar o actualizar la información. Cada bloque está compuesto por una o más celdas. El modelo de GRU propuesto se presenta en el Cuadro 6, este modelo es el mejor encontrado por los distintos algoritmos de afinación de hiper-parámetros con datos teniendo en cuenta la oferta de los demás para el día a predecir y no teniéndolos en cuenta. El modelo ganador hace uso de datos que tienen en cuenta la oferta de los demás el día a predecir y nos referiremos a él más adelante como modelo GRU.

| Tipo de capa                                  | Unidades | Función de Activación |
|---|----------|-----------------------|
| T2V   | 512      | sin                   |
| GRU   | 8        | Tanh                  |
| Dense   | 1        | linear                |
| Optimizador: Adam Tasa de aprendizaje: 0.0001 |          |                       |

Cuadro 6: Modelo GRU + T2V

#### 5.2.6. Long-Short Term Memory (LSTM)

Una LSTM es un bloque de red recurrente que puede tratar con dependencias a largo plazo pero, en lugar de utilizar 2 puertas y un estado oculto como la GRU, utiliza 3 puertas y un estado más para aprender de la información olvidando, actualizando y determinando los próximos valores. El modelo de LSTM propuesto se presenta en el Cuadro 7, este modelo es el mejor encontrado por los distintos algoritmos de afinación de hiper-parámetros con datos teniendo en cuenta la oferta de los demás para el día a predecir y no teniéndolos en cuenta. El modelo ganador hace uso de datos que no tienen en cuenta la oferta de los demás el día a predecir y nos referiremos a él más adelante como modelo LSTM.

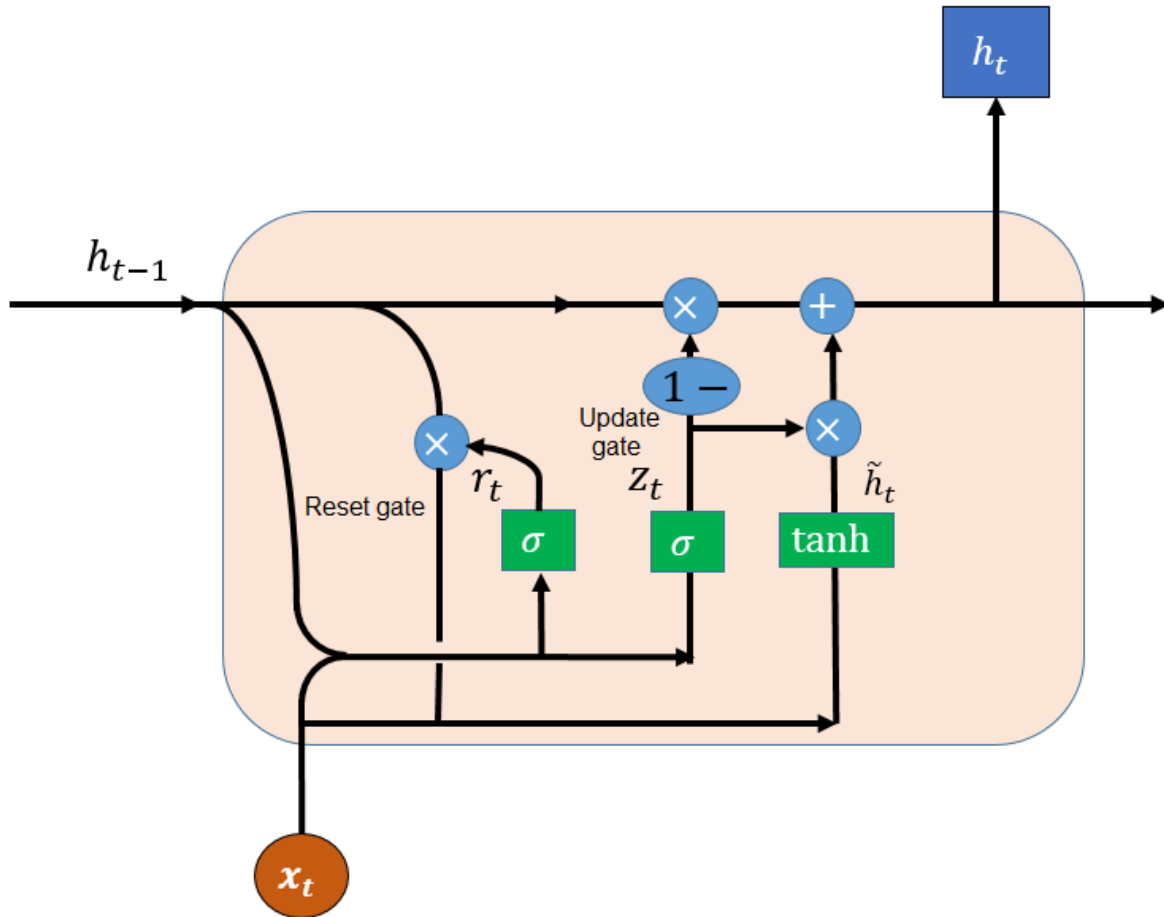


Figura 11: Celda de una GRU. Allí se puede ver el estado  $h$  (*hidden state*) que permite a la celda manejar información arrojada por celdas inmediatamente anteriores para generar una salida. También es posible ver las operaciones como el producto y la suma que se realizan con estos estados y la información que se recibe para el periodo actual  $x^t$  tras haber pasado dicha información junta por funciones de activación como la  $\sigma$  que se encarga de determinar la relevancia (0 es no importa, 1 es realmente importante) de la información y  $\tanh$  que escala los valores entre -1 y 1. Tanto las operaciones como los pasos por las funciones de activación componen las 2 puertas que cambian el estado oculto de la celda  $h$ , la puerta de reinicio determina que información olvidar y la puerta de actualización decide qué información del periodo anterior y del actual incluir. Créditos: Huang y cols. (2019)

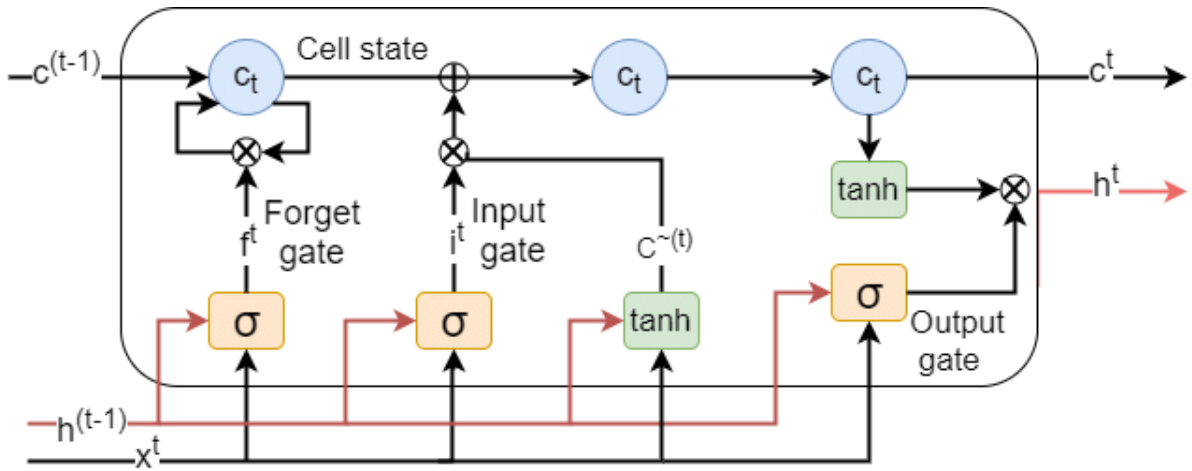


Figura 12: Celda de una LSTM. Allí se pueden ver los dos estados de una celda  $c$  (*cell state*) y  $h$  (*hidden state*) los cuales le permiten a la celda almacenar información relevante de periodos muy anteriores y manejar información arrojada por celdas inmediatamente anteriores respectivamente para generar una salida. Al igual que en la GRU, también es posible ver las operaciones como el producto y la suma que se realizan con estos estados y la información que se recibe para el periodo actual  $x^t$  tras haber pasado dicha información junta por funciones de activación como la  $\sigma$  y  $\tanh$  que cumplen las mismas funciones que en una celda de una GRU. Tanto las operaciones como los pasos por las funciones de activación componen las 3 puertas que cambian los estados  $c$  y  $h$ , la puerta de olvido determina que información dejar de tener presente, la puerta de entrada determina nueva información a considerar y la puerta de salida qué se va a pasar a la siguiente celda. Créditos: Jenkins y cols. (2018)

| Tipo de capa      | Unidades | Función de Activación      |
|-------------------|----------|----------------------------|
| T2V               | 4        | sin                        |
| LSTM              | 16       | Sigmoide                   |
| Densa 1           | 2        | Sigmoide                   |
| Densa 2           | 2        | Tanh                       |
| Dense             | 1        | linear                     |
| Optimizador: Adam |          | Tasa de aprendizaje: 0.001 |

Cuadro 7: Modelo LSTM + T2V

## 6. Resultados

### 6.1. Predicción

Para cada uno de los 36 recursos de generación considerados en el presente estudio se busca cuál es el mejor modelo para predecir su oferta. Es importante resaltar que, este proceso se realiza de manera individual para cada recurso para poder estimar los modelos que buscan predecir cuál es la mejor respuesta del recurso a las las ofertas de los demás.

Figuras 13, 14, 15 y 16 reportan un ejemplo de los mejores modelos obtenidos para cada modelo. De los 36 recursos analizados en 19 de ellos el mejor modelo fue el Base, en 5 el Arima y en los 12 restantes las Redes Neuronales Recurrentes (10 LSTM y 2 GRU). Cabe mencionar que entre los resultados de las redes neuronales recurrentes hubo una gran similitud y fueron pequeñas diferencias las que determinaron el ganador a pesar de que uno contaba con la información sobre la oferta de los demás recursos para el día actual y el otro no. Las métricas promedio de estos modelos se muestran en el Cuadro 8 y el detalle por recurso se muestra en el Cuadro 9. Como puede observarse, en promedio son los modelos más simples los que tiene mejor rendimiento. Sin embargo, cuando se analiza cada recurso de forma individual si se hace evidente las bondades de usar modelo más sofisticados como modelos de aprendizaje de máquinas. De cualquier forma, los resultados sugieren que predecir las ofertas de los agentes es una tarea bastante compleja.




Figura 13: Oferta recurso con mejor modelo base. Fuente: XM. Cálculos del autor.




Figura 14: Oferta recurso con mejor modelo Arima. Fuente: XM. Cálculos del autor.



Figura 15: Oferta recurso con mejor modelo de Red Neuronal Recurrente (LSTM). Fuente: XM. Cálculos del autor.



Figura 16: Oferta recurso con mejor modelo de Red Neuronal Recurrente (GRU). Fuente: XM. Cálculos del autor.

| Modelo     | $R^2$  | MAE   | MSE     | RMSE  | MAPE    |
|------------|--------|-------|---------|-------|---------|
| Base       | 94 %   | 4.40  | 424.14  | 17.35 | 3.07 %  |
| Arima      | 88.2 % | 6.97  | 163.95  | 12.29 | 4.15 %  |
| RNN (LSTM) | 73.5 % | 26.32 | 1695.17 | 40.34 | 28.13 % |
| RNN (GRU)  | 80 %   | 20.74 | 1163.27 | 30.88 | 18.40 % |

Cuadro 8: Métricas promedio por mejor modelo. Cálculos del autor.

| Recurso | $R^2$ | MAE   | MSE      | RMSE  | MAPE    | Tipo            |
|---------|-------|-------|----------|-------|---------|-----------------|
| 1       | 1     | 0.81  | 23.53    | 4.85  | 0.33 %  | Predicción      |
| 2       | 1     | 0.81  | 23.53    | 4.85  | 0.33 %  | Predicción      |
| 3       | 1     | 1.53  | 107.29   | 10.36 | 0.43 %  | Predicción      |
| 4       | 0.99  | 2.26  | 246.52   | 15.70 | 0.91 %  | Predicción      |
| 5       | 0.99  | 4.34  | 148.68   | 12.19 | 2.09 %  | Predicción      |
| 6       | 0.98  | 12.15 | 268.63   | 16.39 | 3.09 %  | Mejor respuesta |
| 7       | 0.96  | 6.91  | 482.20   | 21.96 | 4.56 %  | Predicción      |
| 8       | 0.96  | 12.40 | 377.91   | 19.44 | 3.32 %  | Predicción      |
| 9       | 0.96  | 6.22  | 574.19   | 23.96 | 2.25 %  | Predicción      |
| 10      | 0.95  | 19.76 | 721.49   | 26.86 | 10.45 % | Predicción      |
| 11      | 0.94  | 5.55  | 1,071.41 | 32.73 | 1.91 %  | Predicción      |
| 12      | 0.94  | 8.52  | 502.96   | 22.43 | 7.11 %  | Predicción      |
| 13      | 0.93  | 1.46  | 88.34    | 9.40  | 1.80 %  | Predicción      |
| 14      | 0.93  | 1.15  | 22.89    | 4.78  | 0.87 %  | Predicción      |
| 15      | 0.92  | 1.86  | 112.68   | 10.62 | 2.64 %  | Predicción      |
| 16      | 0.92  | 6.29  | 281.53   | 16.78 | 3.14 %  | Predicción      |
| 17      | 0.92  | 1.54  | 88.91    | 9.43  | 1.85 %  | Predicción      |
| 18      | 0.91  | 7.14  | 356.26   | 18.87 | 3.69 %  | Predicción      |
| 19      | 0.88  | 8.51  | 2,404.09 | 49.03 | 8.57 %  | Predicción      |
| 20      | 0.88  | 5.00  | 94.67    | 9.73  | 3.74 %  | Predicción      |
| 21      | 0.86  | 5.93  | 117.26   | 10.83 | 4.63 %  | Predicción      |
| 22      | 0.86  | 5.65  | 113.61   | 10.66 | 4.54 %  | Predicción      |
| 23      | 0.86  | 12.81 | 1,107.79 | 33.28 | 12.55 % | Predicción      |
| 24      | 0.85  | 1.53  | 135.11   | 11.62 | 2.04 %  | Predicción      |
| 25      | 0.85  | 5.85  | 116.31   | 10.78 | 4.52 %  | Predicción      |
| 26      | 0.83  | 21.99 | 1,221.30 | 34.95 | 25.09 % | Predicción      |
| 27      | 0.82  | 25.24 | 1,341.94 | 36.63 | 31.59 % | Predicción      |
| 28      | 0.81  | 22.17 | 1,014.63 | 31.85 | 23.71 % | Predicción      |
| 29      | 0.77  | 23.95 | 1,238.78 | 35.20 | 29.43 % | Predicción      |
| 30      | 0.77  | 19.12 | 1,152.85 | 33.95 | 24.67 % | Predicción      |
| 31      | 0.73  | 23.59 | 1,371.24 | 37.03 | 26.11 % | Predicción      |
| 32      | 0.71  | 30.34 | 2,271.12 | 47.66 | 33.16 % | Predicción      |
| 33      | 0.68  | 32.34 | 2,648.41 | 51.46 | 37.16 % | Predicción      |
| 34      | 0.63  | 30.56 | 2,240.91 | 47.34 | 30.90 % | Predicción      |
| 35      | 0.62  | 29.32 | 2,057.90 | 45.36 | 33.71 % | Mejor respuesta |
| 36      | 0.56  | 34.09 | 2,702.07 | 51.98 | 36.28 % | Predicción      |

Cuadro 9: Métricas por recurso en su mejor modelo. Cálculos del autor.



## 6.2. Anomalías

La Figura 17 muestra la proporción de alertas que se generaron para cada recurso en la muestra de prueba. Para generar una alerta se compara la predicción con el valor observado de la oferta y se reportan dos casos. Cuando la predicción difiere en una desviación estándar (barras azules) o en dos desviaciones estándar (barras rojas). En términos generales, cuando el umbral es alto (dos desviaciones estándar) y, por lo tanto, el criterio para generar una alerta es más estricto, los recursos térmicos tienen un comportamiento más atípico.




Figura 17: Alertas generadas para cada recursos en la muestra de prueba. Cuando la predicción está a una distancia mayor a una desviación estándar de la oferta observada (barras azules) y cuando está dos desviaciones estándar (barras rojas). Fuente: XM. Cálculos del autor.

## 7. Conclusiones

En este documento se propone una metodología de generación alertas de comportamientos potencialmente anticompetitivos en el mercado mayorista de energía eléctrica en Colombia. La metodología tiene la virtud de ser *ex-ante* a la realización del despacho y puede ser implementada prácticamente en tiempo real. Esta es una característica importante de cara la introducción del mercado intradiario en el mercado mayorista.

La propuesta metodológica tiene dos componentes. De una parte, se utiliza el indicador de oferta residual con el fin de identificar aquellos recursos que podrían tener un impacto importante en el ejercicio de poder de mercado. Una segunda parte utiliza el estado del arte en modelos de predicción con el fin de anticipar las ofertas de energía (precios) esperadas de los recursos de energía. Cuando observamos una diferencia muy notoria entre lo que los modelos predicen y las oferta observadas, se genera una alerta. Cuando la discrepancia supera dos desviaciones estándar, las ofertas anómalas para el periodo en consideración son inferiores al 6% del total de las ofertas dependiendo del recurso.

Combinando las señales del indicador de oferta residual y la generación de alertas de los modelos de predicción se puede generar y priorizar casos sospechosos de prácticas anticompetitivas. Estas alertas pueden ser utilizadas de forma pro-activa, dada su naturaleza *ex-ante* a la realización del mercado o, complementarse con un mecanismo de penalizaciones basado en la externalidades que producen las ofertas anómalas en el precio spot.

## Referencias

- Bataille, M., Steinmetz, A., y Thorwarth, S. (2014). *Screening instruments for monitoring market power in wholesale electricity markets: Lessons from applications in germany*. (Working paper. ECONSTOR)
- Botero, García, J. A., Vélez, J. J., y Guillermo, L. (2013). Mecanismos utilizados para monitorear el poder de mercado en mercados eléctricos: reflexiones para colombia. *Cuadernos de Economía*.
- Comisión de Regulación de Energía y Gas (CREG). (2010). *Medidas para la promoción de la competencia en el mercado mayorista de electricidad*. (Documento CREG-118)
- Goodfellow, I., Bengio, Y., y Courville, A. (2016). *Deep learning*. MIT Press. (<http://www.deeplearningbook.org>)
- Huang, Z., Yang, F., Xu, F., Song, X., y Tsui, K.-L. (2019, 07). Convolutional gated recurrent unit–recurrent neural network for state-of-charge estimation of lithium-ion batteries. *IEEE Access*, PP, 1-1. doi: 10.1109/ACCESS.2019.2928037
- Jenkins, I., Gee, L., Knauss, A., Yin, H., y Schroeder, J. (2018, 11). Accident scenario generation with recurrent neural networks. En (p. 3340-3345). doi: 10.1109/ITSC.2018.8569661
- Kazemi, S. M., Goel, R., Eghbali, S., Ramanan, J., Sahota, J., Thakur, S., ... Brubaker, M. (2019). Time2vec: Learning a vector representation of time.
- Newberry. (2008). Predicting market power in wholesale electricity. *Cambridge Working Papers in Economics Markets*..
- Riascos, A., Bernal, M., de Castro, L., y Oren, S. (2016). Transition to centralized unit commitment: An econometric analysis of colombia's experience. *The Energy Journal*, 37(3).
- Swinand, Scully, Foulkes, y Kessler. (2007). Structure and performance of six european wholesale electricitymarkets in 2003, 2004, and 2005. *London Economics*..
- Twomey, Green, Neuhoﬀ, y Newbery. (2005). *Review of the monitoring of market power*. (Journal of Economic Literature)
- Wolak. (2004). Measuring unilateral market power in wholesale electricity markets: The california market: 1998-2000. *American Economic Review*.

